

UNIVERSIDAD EUROPEA DEL ATLÁNTICO

GRADO EN

Ingeniería Informática



Inteligencia Artificial

Memoria Ocr

Trabajo realizado por:

Daniel Lavín Aguado

Profesor:

Jose Manuel Breñosa

SANTANDER 09-01-2026

Trabajo Final – Inteligencia Artificial

Desarrollo de un sistema OCR basado en Deep Learning

1. Introducción

El reconocimiento óptico de caracteres (OCR) es una de las aplicaciones clásicas de la visión artificial y la inteligencia artificial, cuyo objetivo es convertir información visual contenida en imágenes en texto digital. Este problema resulta especialmente complejo cuando se trata de escritura manuscrita, debido a la elevada variabilidad entre personas, estilos de escritura y posibles ambigüedades entre caracteres.

El objetivo de este trabajo es el desarrollo de un sistema OCR capaz de reconocer caracteres a partir de imágenes externas, sin emplear librerías OCR ya existentes, cumpliendo las restricciones establecidas en el enunciado. Para ello, se han explorado distintos enfoques, comenzando por técnicas clásicas de visión artificial y evolucionando hacia una solución basada en redes neuronales convolucionales (CNN).

Se aplicaron técnicas de entrenamiento prolongado mediante early stopping y data augmentation con el objetivo de mejorar la capacidad de generalización del modelo, observándose una mejora moderada del rendimiento en validación.

El entrenamiento se realizó permitiendo un máximo de 100 epochs, empleando early stopping para evitar el sobreajuste. El proceso se detuvo automáticamente al no observarse mejoras en el conjunto de validación, conservándose los pesos correspondientes al mejor rendimiento obtenido.

2. Descripción del dataset

El conjunto de datos utilizado ha sido construido de forma colaborativa por los alumnos de la asignatura. Está compuesto por 2218 imágenes de caracteres manuscritos, organizadas en tres grandes grupos:

- Letras mayúsculas
- Letras minúsculas
- Dígitos numéricos (0–9)

Las imágenes corresponden a caracteres individuales escritos a mano, almacenados en formato PNG, convertidos a escala de grises y normalizados a una resolución de 64×64 píxeles. Este preprocesado garantiza la homogeneidad de los datos y facilita el entrenamiento de los modelos.

3. Solución aportada

3.1. Enfoque inicial con técnicas clásicas

Como primer acercamiento al problema, se implementó un sistema OCR utilizando técnicas clásicas de visión artificial. En este enfoque, las imágenes fueron representadas mediante píxeles aplanados y posteriormente mediante descriptores HOG (Histogram of Oriented Gradients). Estos descriptores se combinaron con clasificadores como KNN y SVM. Los resultados iniciales mostraron un rendimiento limitado con píxeles crudos, mientras que la combinación HOG + SVM permitió alcanzar una precisión cercana al 70% en el reconocimiento de letras mayúsculas. Este análisis evidenció la importancia de una correcta extracción de características y sirvió como base para evolucionar hacia modelos más avanzados.

3.2. Enfoque basado en Deep Learning

Con el objetivo de mejorar el rendimiento y alinearse con los enfoques actuales de OCR, se implementó una red neuronal convolucional (CNN) utilizando Keras y TensorFlow en Google Colab.

La arquitectura de la red está compuesta por:

Dos capas convolucionales con activación ReLU

- Capas de max pooling para reducción dimensional
- Una capa densa con regularización mediante Dropout
- Una capa de salida con función Softmax

El modelo cuenta con aproximadamente 1,6 millones de parámetros entrenables, lo que permite aprender automáticamente características relevantes a partir de los datos sin necesidad de diseñar descriptores manuales.

3.3. Entrenamiento y evaluación

El conjunto de datos se dividió en un 80% para entrenamiento y un 20% para validación. El entrenamiento se realizó durante 40 epochs, utilizando el optimizador Adam y la función de pérdida categorical crossentropy.

En el caso del reconocimiento de solo letras mayúsculas, la red alcanzó una precisión cercana al 70% en validación, similar al enfoque clásico mejorado. Posteriormente, al ampliar el sistema para incluir mayúsculas, minúsculas y números (aproximadamente 64 clases), la precisión en validación se situó en torno al 50%, resultado coherente con el aumento significativo de la complejidad del problema y la ambigüedad entre caracteres visualmente similares.

3.4. Uso del sistema OCR (Input / Output)

Una vez entrenado el modelo, el sistema permite procesar imágenes externas en formato PNG, no pertenecientes al dataset de entrenamiento. Estas imágenes son preprocesadas y evaluadas por la red neuronal, devolviendo como salida el carácter reconocido en formato de texto digital.

De este modo, el sistema cumple el flujo completo de un OCR: imagen de entrada → procesamiento → salida textual.

3.5. Reconocimiento de palabras y frases

Como ampliación del sistema, se implementó una etapa experimental de segmentación de caracteres mediante detección de contornos con OpenCV. Esta etapa permite separar una imagen que contiene varios caracteres en subimágenes individuales, que son posteriormente reconocidas por la CNN y concatenadas para formar palabras o frases simples.

Esta funcionalidad presenta limitaciones cuando las letras están muy juntas o se trata de escritura cursiva, pero demuestra la viabilidad de extender el sistema hacia un OCR de mayor nivel.

4. Registro de resultados

A lo largo del desarrollo del proyecto se tomaron diversas decisiones basadas en los resultados obtenidos:

KNN con píxeles: rendimiento bajo → descartado

HOG + SVM: mejora significativa → enfoque válido

CNN con mayúsculas: buen equilibrio entre rendimiento y complejidad

CNN completa (mayúsculas, minúsculas y números): mayor dificultad y menor precisión, pero sistema más realista

Este proceso refleja una evolución progresiva y razonada del sistema OCR.

5. Conclusiones

En este trabajo se ha desarrollado un sistema OCR funcional sin recurrir a librerías OCR preentrenadas, empleando técnicas de inteligencia artificial y deep learning. Los resultados obtenidos demuestran la capacidad de las redes neuronales convolucionales para abordar el reconocimiento de caracteres manuscritos, así como las dificultades inherentes al reconocimiento multiclase con alta variabilidad.

Como posibles mejoras futuras se plantea el uso de conjuntos de datos más amplios, arquitecturas más profundas y técnicas de segmentación más avanzadas para mejorar el reconocimiento de palabras y frases completas.

Cabe destacar que el rendimiento obtenido por el sistema se encuentra condicionado por la naturaleza y calidad del conjunto de imágenes empleado durante el proceso de aprendizaje. Al tratarse de un dataset colaborativo con un número limitado de ejemplos por clase y una elevada variabilidad en la escritura manuscrita, el modelo presenta un reconocimiento inferior al esperado en determinadas situaciones, especialmente al ampliar el número de clases. No obstante, este comportamiento es coherente con la complejidad del problema abordado y pone de manifiesto la importancia de disponer de conjuntos de datos más amplios y equilibrados para mejorar la capacidad de generalización del sistema.